

다해상도 이미지를 위한 스테그어날리시스 학습 기법

이인수*, 장어진**, 민지민**, 임경태***, 장한얼***
한밭대학교 컴퓨터공학과 (대학원생)*, (학부생)**, (교수)***

Steganalysis Learning Technique for Multi-Resolution Images

Insu Lee*, Eo-jin Jang**, Jimin Min**, Kyungtae Lim***, Haneol Jang***
Dept. of Computer Engineering, Hanbat National University (Graduate Student)*, (Undergraduate)**, (Professor)***

요 약

모바일 사용자 수가 증가하면서, 스테가노그래피 활용 기기가 데스크톱에서 모바일 기기로 빠르게 전환되고 있다. 모바일 환경은 유일한 커버 이미지를 쉽게 생성할 수 있고 다양한 해상도로 이미지 촬영이 가능하다. 하지만 기존 스테그어날리시스 기술은 해상도를 고정시킨 제한된 실험환경에서 높은 탐지율을 보이며, 학습 시 사용했던 해상도와 다른 테스트 해상도에서는 탐지율이 급격히 하락하는 문제점이 있다. 본 연구에서는 다해상도에서 스테그어날리시스 성능이 하락하는 문제를 해결하기 위해 다해상도 학습법을 제안한다. 다해상도 학습법은 스테그어날리시스 모델을 학습할 때 다양한 해상도의 이미지 데이터를 훈련 데이터로 사용하는 방법이다. 다해상도 학습법을 적용한 스테그어날리시스 모델은 기존의 고정된 크기를 사용하는 모델에 비해 다양한 해상도 뿐만 아니라 학습에 사용하지 않은 해상도에 대해서도 우수한 성능을 보여주었으며 평균적으로 96.05%의 탐지율을 달성하였다.

주제어 : 스테그어날리시스, 딥러닝, 합성곱신경망, 디지털포렌식, 컴퓨터비전

ABSTRACT

As the number of mobile users increases, devices utilizing steganography are rapidly transitioning from desktops to mobile devices. The mobile environment can easily generate unique cover images, and images can be taken in various resolutions. However, the existing steganalysis methods show high detection accuracy in a limited experimental environment where the resolution is fixed, and there is a problem in that the detection rate drops sharply at a test resolution different from the resolution used for training. We propose a multi-resolution learning method to solve the problem of steganalysis performance degradation at multi-resolution. The multi-resolution learning method uses images of various resolutions as training data to learn a steganalysis model. The steganalysis model using the multi-resolution learning method showed excellent performance at various resolutions as well as resolutions not used for training, compared to the existing model with the fixed resolution, and achieved an average detection rate of 96.05%.

Key Words : Steganalysis, Deep Learning, CNN, Digital Forensics, Computer Vision


1. 소 개

스테가노그래피는 이미지를 비롯한 콘텐츠에 비밀 메시지를 보이지 않게 삽입함으로써 은밀하게 상대방에게 비밀 메시지를 전달하는 비밀 통신 기술이다. 눈으로 보기에는 평범한 이미지로 보이기에 복호화하기 전까지는

※ 이 논문은 ETRI부설연구소의 위탁연구과제[2021-048]로 수행한 연구결과입니다.
※ 이 논문의 내용을 발표하는 때에는 ETRI부설연구소에서 수행한 위탁결과임을 밝혀야 합니다.
▪ Received 30 November 2021, Revised 02 December 2021, Accepted 04 March 2022
▪ 제1저자(First Author) : Insu Lee (Email : 30211054@edu.hanbat.ac.kr)
▪ 교신저자(Corresponding Author) : Haneol Jang (Email : hejang@hanbat.ac.kr)

비밀 메시지가 삽입된 이미지인지 탐지하기 어렵다. 스테가노그래피는 테러, 기밀정보 유출 등 악의적인 목적으로 활용될 수 있기 때문에 의심 콘텐츠가 정보가 삽입된 스테고인지 정보가 삽입되지 않은 커버인지 판별하는 기술은 매우 중요하다. 스테가노그래피에서 사용하는 메시지 삽입영역은 크게 공간영역과 압축영역으로 분류할 수 있다. 공간영역 스테가노그래피는 최하위 비트(Least Significant Bit, LSB)만 변경하는 간단한 알고리즘부터 최하위로부터 N개 비트까지 사용하는 알고리즘 등이 있다. 압축영역 스테가노그래피는 JPEG 이미지의 양자화된 이산 코사인 변환(Discrete Cosine Transform, DCT) 계수 값을 변경하는 방법을 주로 사용한다. 최근에는 딥러닝을 활용하여 이미지 픽셀값을 변경하는 스테가노그래피 기법도 등장하였다.

스테그어날리시스는 원본 이미지인 커버 이미지와 스테가노그래피로 생성한 스테고 이미지를 분류하는 기술이며, 최근에는 딥러닝 기반의 스테그어날리시스까지 발전하였다. 스테그어날리시스에 대한 필요성이 높아지면서 2020년에는 이미지 스테그어날리시스 대회가 캐글에서 개최되었다. 해당 대회에서는 ImageNet 데이터셋으로 미리 학습한 EfficientNet[1]을 전이학습하는 것만으로 스테그어날리시스 최신 성능을 보여주던 SRNet[2] 대비 더 높은 성능을 보여주었다[3]. 대회 결과를 통해 스테그어날리시스를 위한 네트워크 구조를 새롭게 설계하는 것보다는 ImageNet 데이터셋으로 미리 학습한 모델을 스테그어날리시스 문제에 적합하게 활용하는 것이 스테그어날리시스 성능 향상에 더 도움이 된다는 것을 알게 되었다.



〈Figure 1〉 Smartphone penetration rate of Korea in 2012-2021

한편, [그림 1]은 한국갤럽조사연구소에서 2021년 6월 3일에 발표한 국내 연령별 모바일 보급률[4]이다. 2021년 6월 기준 20대부터 50대까지의 모바일 보급률은 100%에 육박하며 60대 또한 80% 이상의 모바일 보급률을 보인다. 모바일 시장이 활성화되면서 데스크톱에서 메일이나 메시지를 주고받던 시절과 비교해 모바일을 통해 메시지를 주고받는 일이 훨씬 많아졌다. 비교적 장소에 제약이 있던 데스크톱에 비해 모바일은 장소의 제약이 적고, 훨씬 간편하게 메시지를 전달할 수 있다. 스테가노그래피 또한 데스크톱에서 모바일로 활용 기기가 빠르게 전환되는 중이다. 실제로 안드로이드 환경이나 iOS 환경에서 스테가노그래피 앱이 앱스토어에 공식적으로 등록된 것을 확인할 수 있으며, 앱 사용자 수는 꾸준히 증가하는 모습을 보인다[5].

스테가노그래피가 모바일로 빠르게 전환되는 것에 대응하기 위해 모바일 환경에 맞는 스테그어날리시스 기술 개발이 매우 필요한 상황이다. 모바일 기기는 손쉽게 유일한 커버 이미지를 생성할 수 있기 때문에 커버와 스테고 간의 차이값을 테스트 환경에서 사용할 수 없고 스테고 이미지만으로 비밀 메시지 유무를 판별해야 한다. 또한, 모바일 기기의 종류와 카메라 설정에 따라 다양한 해상도의 이미지를 생성하기 때문에 이에 대응하기 위한 다해상도 스테고 이미지 판별 기술이 필요하다.

영상처리에서 주로 사용하는 Convolutional Neural Network(CNN) 모델은 훈련 해상도와 다른 테스트 해상도의 이미지를 분석할 때 성능 하락이 발생하는 문제점이 있다[6]. 즉, 해상도를 고정시키고 스테그어날리시스 모델을 학습하는 경우 학습 해상도와 다른 테스트 해상도에 대해서는 스테고 판별을 수행할 수 없다.

따라서 본 연구에서는 다해상도 이미지에 대한 스테그어날리시스 모델의 성능 하락 문제를 해결하기 위해 다해상도 학습법을 제안한다. 다해상도 학습법은 다양한 해상도의 스테고 이미지 판별율을 향상시키기 위해 매 학습배치마다 이미지 해상도를 변경하여 학습하는 방법이다. 다해상도 학습법을 사용한 스테그어날리시스 모델은 고정된 크기를 활용한 모델 대비 평균적으로 4.17%의 탐지율 향상을 보였다.

II. 관련 연구

SRNet은 최초의 딥러닝 기반 스테그어날리시스 모델이며 공간영역 스테가노그래피인 WOW[7], HILL[8], S-UNIWARD[9], MiPOD[10]와 JPEG 압축영역 스테가노그래피인 J-UNIWARD[9]와 UED-JC[11] 알고리즘에 대해 우수한 성능을 보여주었다[2]. 2020년 캐글에서 개최된 "ALASKA2 Image Steganalysis" 대회에서는 ImageNet 데이터셋을 이용하여 사전학습한 EfficientNet을 전이학습한 스테그어날리시스 모델이 SRNet보다 더 높은 성능을 보였다. 이는 스테그어날리시스에 특화된 모델을 새롭게 만드는 것보다 기존 CNN 모델을 활용하여 개선하는 것이 스테그어날리시스에서 더 좋은 성능을 보여줄 수 있음을 시사하였다. 대회에서 성능을 향상시키기 위한 모델 수정 방법은 크게 2가지로 나뉜다. 첫 번째는 스테가노그래피가 생성하는 미세 신호를 크게 왜곡하는 down-sampling 횟수를 줄이는 방법이고, 두 번째는 미세 신호를 처리하기 용이하도록 down-sampling 전에 레이어를 추가하는 방법이다. 먼저 down-sampling 횟수를 줄이는 방법은 네트워크 앞단에서 down-sampling을 수행하는 레이어를 수정하여 입력 해상도를 유지한 채 많은 수의 합성곱 연산을 수행하는 것이다. 네트워크 앞단의 해상도를 유지하도록 수정한 EfficientNet은 성능 향상을 보였으나, 연산 수가 크게 증가하는 문제점이 있다. 레이어를 추가하는 방법은 down-sampling을 수행하기 전에 여러 개의 합성곱 레이어를 추가하여 해상도를 유지한 채 여러 번의 합성곱 연산을 수행하는 것이다. 앞에서 언급한 down-sampling 횟수를 줄이는 방법에 비해 탐지율은 약간 하락하지만 더 적은 연산 수를 필요로 한다는 점에서 장점이 있다고 밝혀졌다[3]. 하지만 앞서 소개한 스테그어날리시스 기법들은 고정된 크기의 데이터셋을 사용한 실험결과이며 학습 해상도와 다른 테스트 해상도 사용 시 스테그어날리시스 성능이 크게 하락하는 문제가 있다.

객체 탐지 모델에서도 학습과 테스트 간의 해상도가 다른 경우 모델의 성능이 하락하는 문제가 발생한다. FixRes는 훈련할 때의 객체 크기와 테스트할 때의 객체 크기가 다를 때 성능 하락이 발생하는 문제를 해결하고자 크기조절 함수를 사용하여 훈련 데이터와 테스트 데이터 모두 해상도를 변경한다. 이 기법은 학습과 테스트 간의 해상도 차이가 발생하는 이미지에 대해 높은 탐지율 향상을 보였다[6]. 하지만 스테그어날리시스에서는 주목하는 스테가노그래피 메시지 삽입 흔적은 미세 신호이기 때문에 크기조절 함수를 사용하면 미세 신호가 크게 손상되는 문제점이 있다.

따라서 본 연구에서는 미세 신호를 보존하면서 학습과 테스트 간의 해상도 차이가 발생하는 이미지에 대해 높은 탐지율을 달성하기 위해 이미지 절삭을 이용한 다해상도 학습법을 제안한다. 다해상도 학습법은 매 학습 배치마다 이미지 해상도를 변경하여 학습하는 방법이며, 다해상도 학습법을 활용한 스테그어날리시스 모델은 고정된 크기를 활용한 모델 대비 평균적으로 4.17%의 탐지율 향상을 보였다.

III. 다해상도 이미지를 위한 스테그어날리시스 학습 기법

3.1 실험 데이터 분석

실험 데이터셋으로 다양한 모바일 기기와 공간영역 스테가노그래피 앱으로 생성한 StegoAppDB[5]을 사용하였다. 커버 이미지는 89,900장이고 스테고 이미지는 396,600장이다. 실험에 사용한 공간영역 스테가노그래피 앱은 MobiStego, PocketStego, Steganography-Meznik, Pictograph 총 4종이다. 픽셀당 비트 수 (Bits Per Pixel, BPP)는 $0 < BPP \leq 0.25$ 이며, 이미지 크기는 모두 $512 \times 512 \times 3$ 인 컬러 이미지를 사용하였다.

[그림 2]는 커버와 스테고 이미지 간의 차이값을 시각화한 그래프이며 각 스테가노그래피 앱의 메시지 삽입 영역을 보여준다. MobiStego의 경우 메시지 삽입영역이 이미지의 상단에 집중된 모습을 보이며, PocketStego는 메시지 삽입영역이 이미지의 좌측에 집중되어 있다. Steganography-Meznik은 메시지 삽입영역이 흩뿌리듯 이미지 전체에 분포되어 있으며, Pictograph는 메시지 삽입영역이 MobiStego와 동일하게 이미지 상단에 집중되어 있다.

[그림 3]는 이미지의 RGB 채널 중 어느 채널에 메시지가 삽입되어 있는지를 비율로 보여준다. MobiStego의 경우 RGB 채널이 대략 1:1:1 비율로 각 채널에 고르게 메시지가 삽입된 모습을 보였으며, PocketStego는 B 채널에만 메시지가 삽입되었다. Steganography-Meznik은 MobiStego와 비슷한 양상으로 모든 채널이 고르게 약 1:1:1 비율로 삽입되었으며, Pictograph는 G 채널에만 메시지를 삽입하였다.

[그림 4]는 이미지의 RGB 채널을 각각 8비트로 분리하고 각 채널별 8비트 중 어느 비트에 메시지가 삽입되었는지 비율로 보여준다. 일반적으로 스테가노그래피는 높은 비탐지성을 달성하기 위해 LSB를 비롯한 하위

비트를 주로 메시지 삽입영역으로 사용한다. MobiStego의 경우 8비트 중 마지막 2개의 비트에 주로 메시지를 삽입하며, 그 중에서도 마지막 비트인 LSB에 좀 더 많은 메시지를 삽입하였다. PocketStego와 Pictograph는 둘 다 동일하게 LSB에만 메시지를 삽입하였고, Steganography-Meznik은 MobiStego와 유사하게 마지막 2개 비트에 메시지를 삽입하였고 마지막 비트에 더 많은 메시지를 삽입하였다.

3.2 다해상도 학습 방법

모바일 환경에서는 이미지 데이터가 다양한 해상도로 존재한다. 모바일 환경에서 생성되는 스테고 이미지 역시 다양한 해상도로 존재하며, 본 연구에서는 이 이미지가 스테고 이미지인지 커버 이미지인지 판별해야 한다. 하지만 CNN 모델은 다양한 해상도 이미지를 판별할 때 훈련했던 해상도와 다른 테스트 해상도에서 성능 하락이 발생한다. 본 연구에서는 [그림 5]와 같이 학습과 테스트 간의 해상도 차이에서 발생하는 성능 하락 문제를 해결하고자 다해상도 학습법을 제안한다.

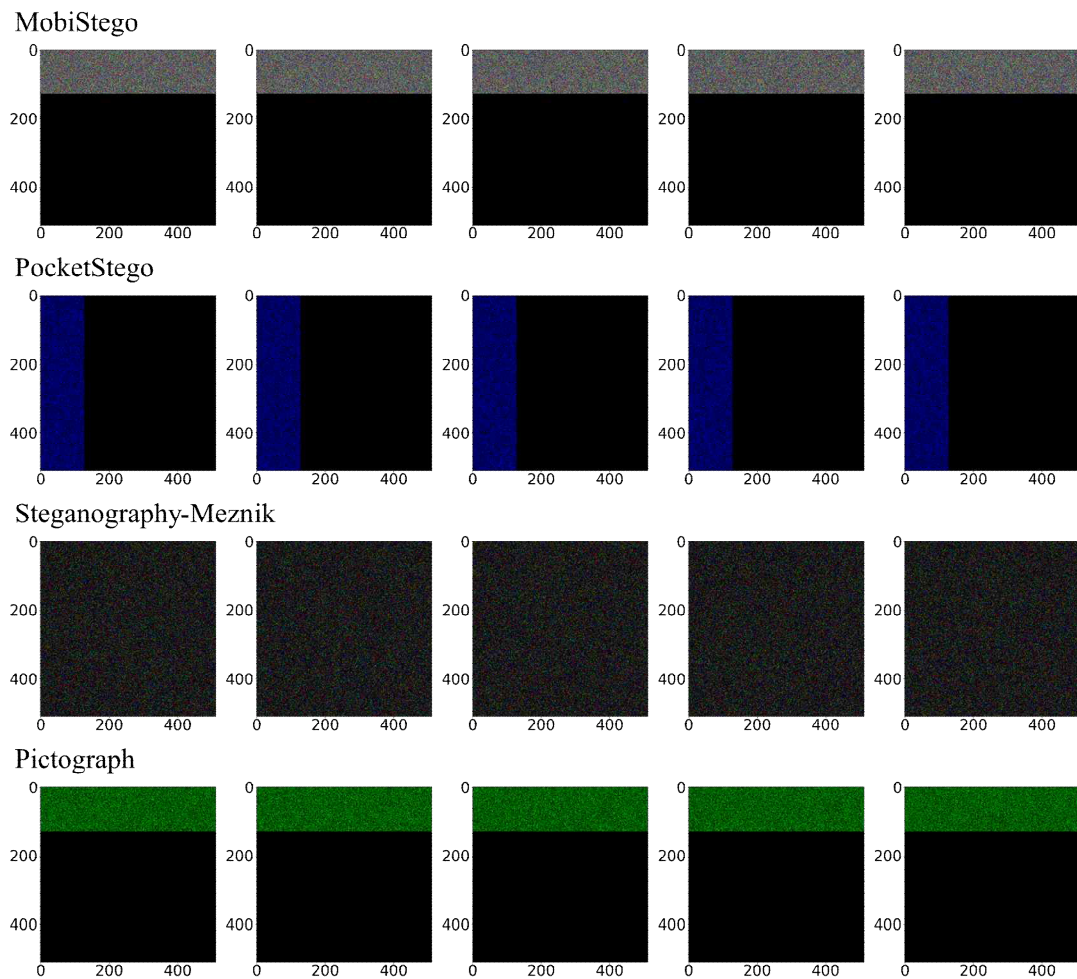
먼저 스테고 이미지에서 메시지가 삽입되는 영역을 절삭하여 다양한 해상도의 이미지를 생성한다. 다음으로 커버 이미지 역시 스테고 이미지와 동일하게 절삭하여 데이터를 섞는다. 이후 다양한 해상도의 스테고 이미지와 커버 이미지가 섞인 훈련 데이터를 사용하여 다양한 해상도에 대해 유연한 모델을 학습했다.

스테고 이미지는 대개 이미지 상단이나 좌측에 메시지 삽입영역이 편향되거나 전체적으로 흩뿌린 형태를 지닌다. 실험에서 사용한 MobiStego, PocketStego, Steganography-Meznik, Pictograph 스테가노그래피 앱으로 생성한 스테고 이미지 역시 3.1의 분석 결과처럼 비슷한 양상을 보인다. 따라서 다해상도 이미지를 생성할 때 스테고 이미지의 메시지 삽입영역이 포함되도록, 이미지의 좌측 상단을 기준으로 128×128, 192×192, 256×256, 320×320, 384×384 해상도로 절삭하여 학습 데이터로 활용하였다. 학습을 진행할 때는 매 학습 배치마다 임의의 해상도를 선택하도록 설정하였다. 단일 해상도 학습 모델의 경우에는 256×256 해상도로 고정하여 학습을 진행하였다. 테스트 해상도는 학습 시 사용하지 않은 해상도를 추가하여 64×64, 128×128, 192×192, 256×256, 320×320, 384×384, 512×512를 사용하였다. 학습, 검증, 테스트 데이터셋 비율은 3:1:1로 설정하여 학습 이미지 291,900장, 검증 이미지 97,300장, 테스트 이미지 97,300장을 사용하였다.


실험에 사용한 스테그어날리시스 네트워크 구조는 최신 성능을 보이는 EfficientNet과 EfficientNet Post-stem ResNet(EfficientNet PRN)[3]이고 다해상도 학습법을 적용한 모델과 고정 해상도를 사용한 모델을 구별하여 총 4가지 모델을 학습하고 성능을 비교하였다. 모든 스테그어날리시스 모델은 ImageNet 데이터셋으로 사전학습한 모델을 전이학습하였다. 커버와 스테고 4종을 한 번에 판별하는 다중 판별 모델을 학습하여 성능을 평가하였다. 커버와 스테고를 판별하는 이진 판별에서는 스테고 4종에 대한 확률값을 합하여 스테고 확률로 계산하였다.

스테그어날리시스 모델 성능 평가를 위한 지표로 커버와 스테고 이진 판별 성능 지표로 the weighted Area Under the Receiver Operating Characteristic Curve (wAUC)와 탐지율을 사용하였다. 커버와 스테고 4종을 한 번에 판별하는 다중 판별 성능 지표로 탐지율을 사용하였다.


학습률의 경우, 실험을 진행했을 때 0.0001은 학습 진행 속도가 비교적 느리고 성능 향상이 미미했다. 실험을 진행하면서 학습률은 0.001이 최적값이었기에, 이후 본 실험에서는 학습률로 0.001을 사용하였다. 스테고 이미지는 픽셀값에 메시지가 삽입되기 때문에 픽셀값에 변화를 주지 않은 채 데이터 증대를 진행해야 한다. 따라서 데이터 증대 방법은 이미지 좌우 반전과 임의의 90도 회전만을 사용하였다. 활성화 함수는 학습 속도를 빠르게 진행하기 위해 Adaptive Optimizer 계열을 사용하였다. 본 연구에서는 활성화 함수로 AdamW[12]를 선택하였는데, Adam[13]에서 L2 Regularization을 진행하는 경우 Decay Rate가 낮아지면서 학습을 진행해도 일반화 능력이 비교적 뒤떨어진다. 이를 개선하여 만들어진 활성화 함수가 AdamW이며, 실제 실험을 진행하면서 학습 진행이 빠르고 높은 성능을 보여주었기에 해당 활성화 함수를 선택하였다. 가중치 감쇠는 실험을 통해 최적값으로 나타난 0.0001을 사용하였다. Epoch는 20보다 더 큰 Epoch에서 모델 성능의 개선은 보이지 않았기에 20으로 진행하였다. 배치 사이즈는 32로 진행하였다.



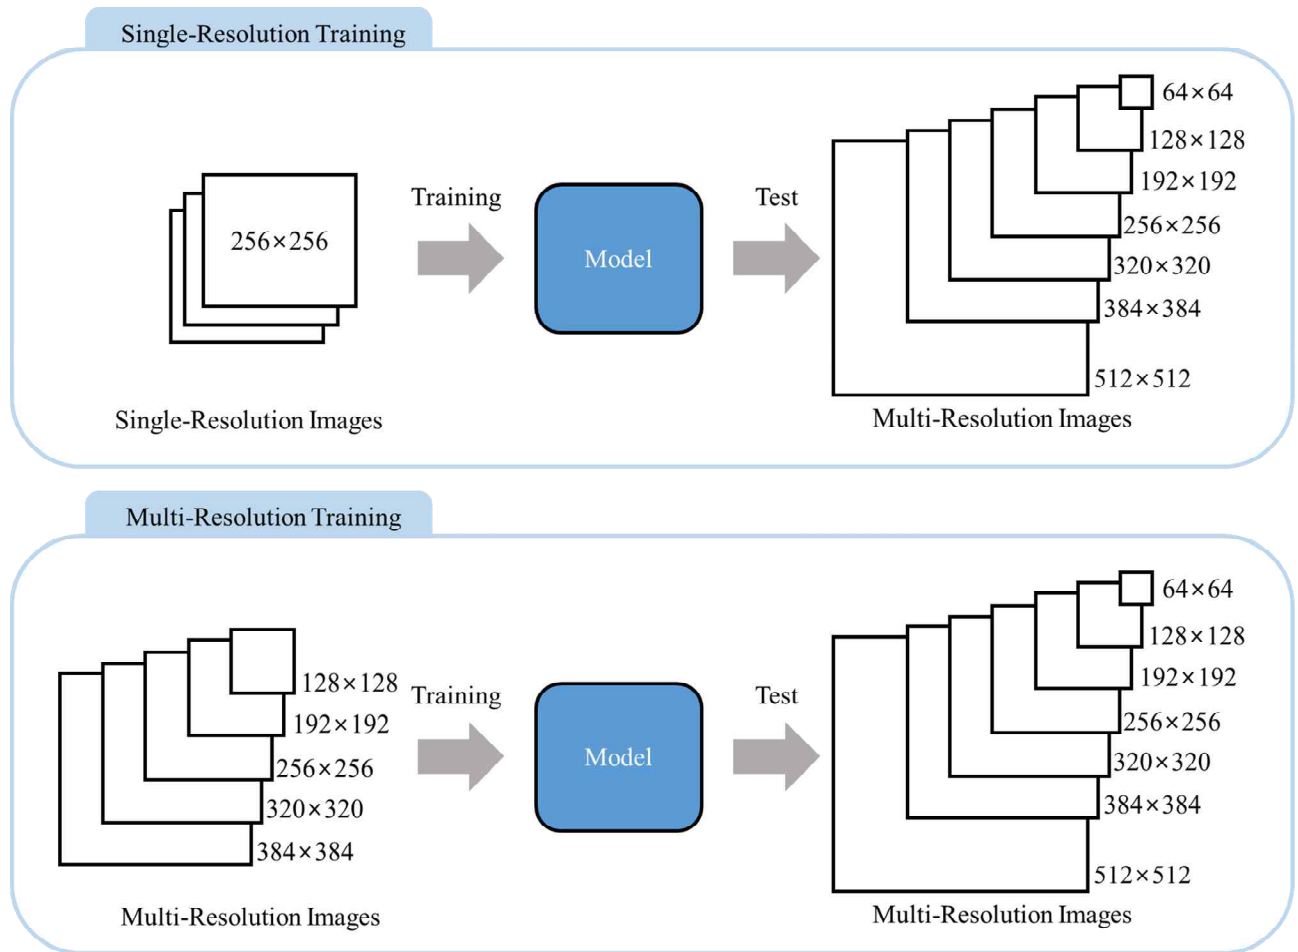
(Figure 2) Areas of message bits insertion in stego images



(Figure 3) Message bits insertion rate graphs of RGB channels in stego images



(Figure 4) Message bits insertion rate graphs of pixels bits in stego images

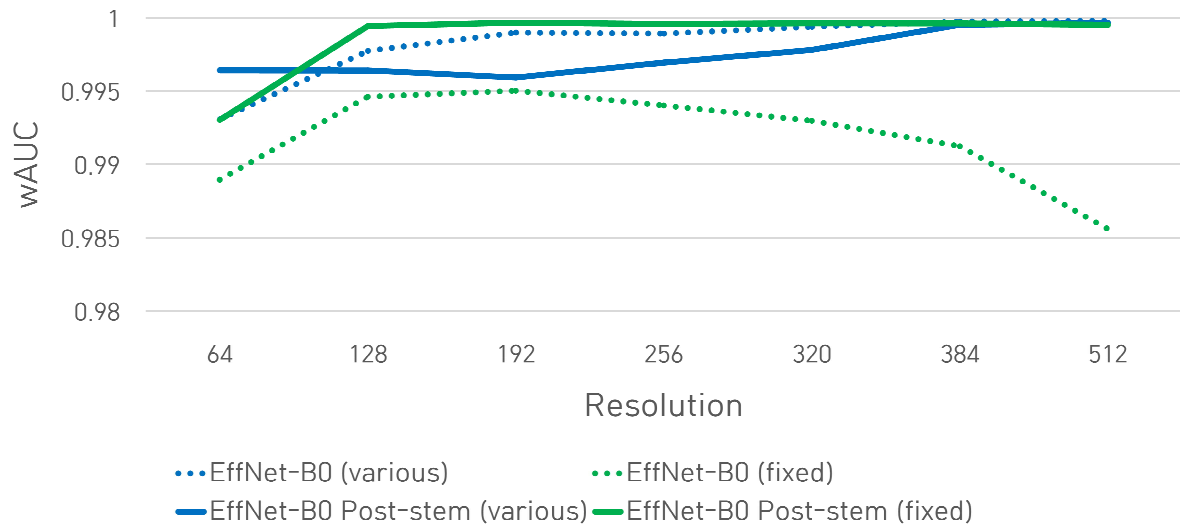


〈Figures 5〉 Single-Resolution Training Method and Multi-Resolution Training Method

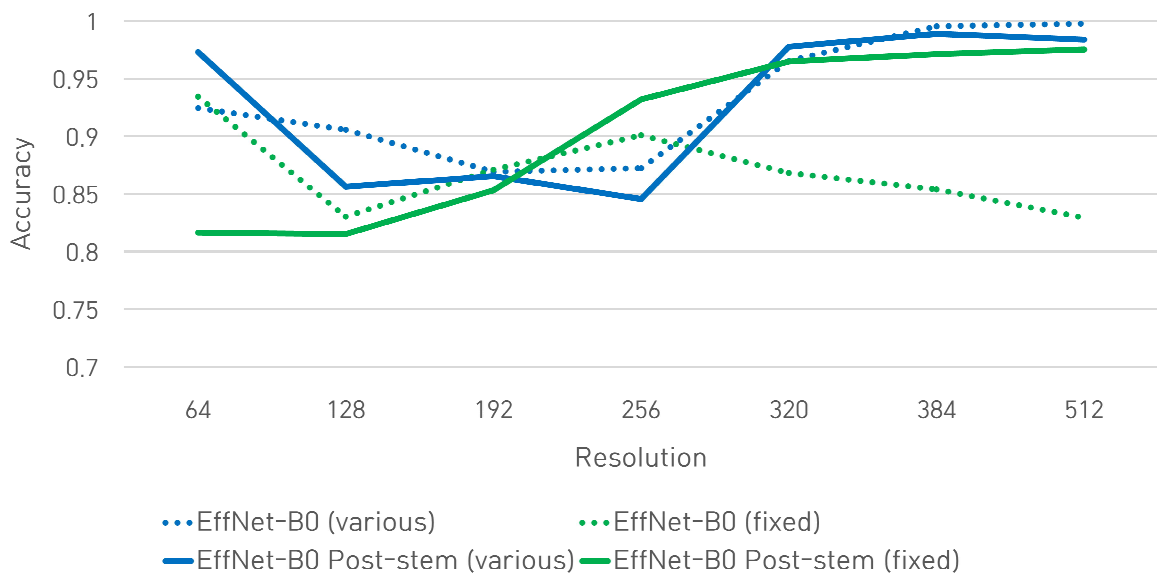
IV. 실험 결과

테스트 해상도 변화에 따른 스테그어날리시스 모델 성능을 평가하였다. [그림 6]과 [그림 7]은 커버와 스테고를 분류하는 이진 판별 wAUC와 탐지율 그래프이다. 다해상도 학습법을 적용한 EfficientNet 모델은 단일 해상도 학습을 진행한 모델 대비 모든 해상도에서 더 높은 이진 판별 wAUC를 보였다. 이진 판별 탐지율 또한 다해상도 학습법을 적용한 EfficientNet 모델이 단일 해상도 모델 대비 평균 6.31% 성능 향상을 보였다. 특히, 학습 시 사용하지 않은 512x512 해상도에서 다해상도 훈련법을 적용한 모델이 단일 해상도 모델에 비해 12.80% 탐지율 상승을 보였다. 다해상도 학습법을 적용한 EfficientNet PRN 모델은 단일 해상도 모델에 비해 이진 판별 wAUC에서 0.11% 하락하였으나 탐지율에서는 2.30% 향상하였다.


[그림 8]은 MobiStego, PocketStego, Steganography-Meznik, Pictograph 스테고 4종과 커버를 포함한 총 5종 판별 정확도 그래프이다. 다해상도 학습법을 적용한 EfficientNet 모델이 단일 해상도 학습한 모델보다 평균 4.92% 다중 탐지율 향상을 보였다. 특히, 학습 시 사용하지 않은 512x512 해상도에서 다해상도 훈련법을 적용한 모델이 단일 해상도 모델에 비해 17.03% 탐지율 상승을 보였다. 다해상도 학습법을 적용한 EfficientNet PRN 모델은 단일 해상도 모델에 비해 다중 탐지율이 3.41% 향상하였다. 다해상도 학습법을 적용한 모델 2종은 단일 해상도 모델 2종에 비해 평균적으로 4.17% 다중 탐지율 향상을 보였다.



〈Figure 6〉 wAUC of each resolution in binary classification of test




〈Figure 7〉 Accuracy of each resolution in binary classification of test



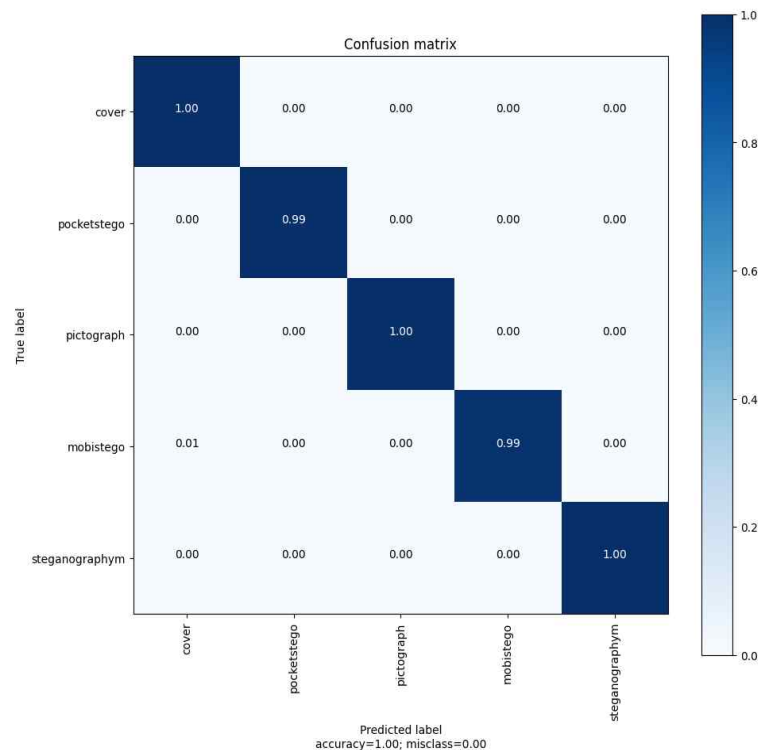
〈Figure 8〉 Accuracy of each resolution in various classification of test

[그림 9]는 256×256 해상도의 데이터를 학습한 EfficientNet-B0 모델의 512×512 테스트 다중 판별 오차 행렬이다. 행은 실제 정답 클래스를 나타내고 열은 모델의 판별 결과를 나타낸다. 스테고 4종에 대해서는 전반적으로 높은 탐지율을 보였으나 커버 이미지를 PockerStego로 판별하는 오차율이 76%였다. 학습한 해상도와 다른 테스트 해상도 환경에서 성능 하락이 크게 발생한 것을 확인할 수 있었다.



〈Figure 9〉 A confusion matrix in 512×512 of EfficientNet-B0 trained by single-resolution training method

[그림 10]은 다해상도 데이터를 학습한 EfficientNet-B0 모델의 512×512 테스트 다중 판별 오차 행렬이다. 다해상도 학습법에서 사용하지 않은 512×512 해상도에서 커버와 스테고 모두 매우 높은 탐지율을 보였다.



〈Figure 10〉 A confusion matrix in 512×512 of EfficientNet-B0 trained by multi-resolution training method

V. 결 론

스테가노그라피는 테러, 기밀정보 유출 등 악의적인 목적으로 활용될 수 있는 기술이기 때문에 디지털포렌식 수사 과정에서 의심 콘텐츠가 정보가 삽입된 스테고인지 정보가 삽입되지 않은 커버인지 판별하는 스테그어널리시스 기술은 매우 중요하다. 최근에는 모바일 기기의 보급률이 증가함에 따라 스테가노그라피 또한 데스크톱에서 모바일 기기로 전환되는 추세이다. 다양한 스테가노그라피 앱이 등장하였고 앱 다운로드 수 또한 급증하고 있다. 모바일 기기는 유일한 커버 이미지를 생성하기 용이하며 다양한 해상도의 이미지 촬영이 가능하다. 따라서 커버 이미지 없이 스테고 이미지만으로 스테고 판별을 수행해야 하며 다양한 해상도에 대해서도 높은 탐지율을 보이는 스테그어널리시스 기술 연구가 필요하다.

기존 스테그어널리시스 기법은 고정된 해상도에서만 학습과 테스트를 수행하는 제한된 실험환경에서 개발되었다. 이러한 단일 해상도 학습 모델은 훈련한 해상도와 다른 해상도의 이미지에 대해서 성능이 하락하는 문제가 있었다. 해상도 차이에서 발생하는 성능 하락 문제를 해결하기 위해 본 연구에서는 다해상도 학습법을 제안하였다. 다해상도 학습법은 학습 과정에서 매 학습 배치마다 임의의 해상도 이미지를 선택하여 다양한 해상도에 대해 높은 탐지율을 보이도록 설계한 학습 방법이다. 스테그어널리시스 문제 특성상 미세 신호의 손상이 발생하지 않는 해상도 조절이 필요하기 때문에 메시지 은닉 영역으로 추정되는 영역을 절삭하는 방법을 사용하였다. 실험결과를 통해 다해상도 학습법을 적용한 스테그어널리시스 모델이 단일 해상도 학습 모델 대비 다양한 해상도 이미지에 대하여 평균적으로 우수한 성능을 보임을 확인하였다. 특히, 학습에 사용하지 않은 512×512 해상도에 대해서 다해상도 학습법을 적용한 EfficientNet 모델은 단일 해상도 학습 EfficientNet 모델에 비해 17.03% 다중 탐지율 향상을 보였다. EfficientNet과 EfficientNet PRN 모두 다해상도 학습법 적용 시 탐지율이 향상되었고 평균 4.17% 탐지율 향상을 보였다.

참 고 문 헌 (References)

- [1] Mingxing Tan and Quoc V. Le., EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks, International Conference on Machine Learning(ICML), 2019.
- [2] Mehdi Boroumand, Mo Chen and Jessica Fridrich, "Deep Residual Network for Steganalysis of Digital Images," in IEEE Transactions on Information Forensics and Security, Vol. 14, pp.1181-1193, 2018.
- [3] Yassine Yousf, Jan Butora, Jessica Fridrich and Clément Fuji Tsang, "Improving EfficientNet for JPEG Steganalysis," in IH&MMSec '21: Proceedings of the 2021 ACM Workshop on Information Hiding and Multimedia Security, pp.149-157, 2021.
- [4] 한국갤럽연구소.(2021). 2012-2021 스마트폰 사용률 & 브랜드, 스마트워치, 무선이어폰에 대한 조사, <https://www.gallup.co.kr/gallupdb/reportContent.asp?seqNo=1217>
- [5] Jennifer Newman, Li Lin, Wenhao Chen, Stephanie Reinders, Yangxiao Wang, Min Wu and Yong Guan, "StegoAppDB: a Steganography Apps Forensics Image Database," in Electronic Imaging, Media Watermarking, Security, and Forensics 2019, pp.536-1-536-12, 2019.
- [6] Hugo Touvron, Andrea Vedaldi, Matthijs Douze and Hervé Jégou, "Fixing the train-test resolution discrepancy," in NIPS'19: Proceedings of the 33rd International Conference on Neural Information Processing Systems, No.741, pp.8252-8262, 2019.
- [7] V. Holub and J. Fridrich, "Designing Steganographic Distortion Using Directional Filters," in IEEE Workshop on Information Forensic and Security (WIFS), 2012.
- [8] B. Li, M. Wang, J. Huang, and X. Li, "A new cost function for spatial image steganography," in 2014 IEEE International Conference on Image Processing (ICIP), pp.4206-4210, 2014.
- [9] V. Holub, J. Fridrich and T. Denemark, "Universal Distortion Function for Steganography in an Arbitrary Domain," in EURASIP Journal on Information Security, 2014.
- [10] V. Sedighi, R. Coganne and J. Fridrich, "Content-Adaptive Steganography by Minimizing Statistical Detectability," in IEEE Transactions on Information Forensics and Security, Vol.11, No.2, pp.221-234, 2016.
- [11] L. Guo, J. Ni, and Y. Q. Shi, "Uniform embedding for efficient JPEG steganography", in IEEE Transactions on Information Forensics and Security, Vol.9, pp.814-825, 2014.
- [12] Ilya Loshchilov and Frank Hutter, "Decoupled Weight Decay Regularization", in 7th International Conference on Learning Representations (ICLR), 2019.
- [13] Diederik P. Kingma and Jimmy Lei Ba, "Adam: A Method for Stochastic Optimization", in 3rd International Conference on Learning Representations (ICLR), 2015.

저 자 소 개



이 인 수 (Insu Lee)

준회원

2021년 2월: 건양대학교 융합IT학과 학사

2021년 3월 ~ 현재: 한밭대학교 컴퓨터공학과 석사과정

관심분야: 디지털 포렌식, 컴퓨터비전 등



장 어 진 (Eo-Jin Jang)

준회원

2019년 3월 ~ 현재: 한밭대학교 컴퓨터공학과 학사과정

관심분야: 디지털 포렌식, 컴퓨터비전 등



민 지 민 (Jimin Min)

준회원

2019년 3월 ~ 현재: 한밭대학교 컴퓨터공학과 학사과정

관심분야: 디지털 포렌식, 컴퓨터비전 등



임 경 태 (Kyungtae Lim)

준회원

2010년 2월: 단국대학교 컴퓨터공학과 학사

2014년 2월: 한국과학기술원 웹사이언스공학과 석사

2020년 2월: Ecole Normale Supérieure (ENS) 박사

2020년 1월 ~ 2021년 2월: 한국원자력연구원 선임연구원

2021년 3월 ~ 현재: 한밭대학교 컴퓨터공학과 조교수

관심분야: 디지털포렌식, 자연어처리, 머신러닝 등



장 한 열 (Haneol Jang)

준회원

2012년 2월: 아주대학교 정보컴퓨터공학부 학사

2014년 2월: 한국과학기술원 전산학과 석사

2018년 2월: 한국과학기술원 전산학부 박사

2018년 4월 ~ 2018년 10월: 네이버 클로바 인공지능 연구원

2018년 10월 ~ 2020년 8월: 국가보안기술연구소 선임연구원

2020년 9월 ~ 현재: 한밭대학교 컴퓨터공학과 조교수

관심분야: 디지털포렌식, 컴퓨터비전, 머신러닝 등